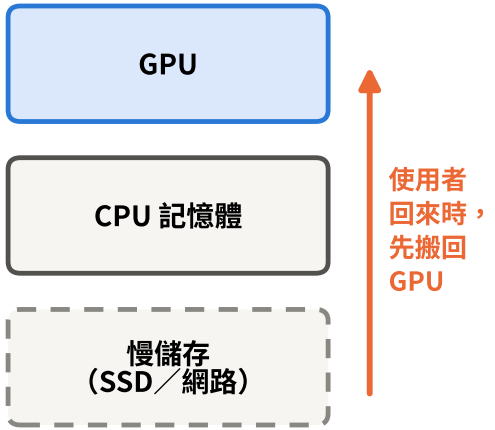
## 要解決的問題




對話停下來時，KV 被移出 GPU
（KV＝已算好的中間結果）
32K 對話的 KV 有 4.0 GiB

**使用者等的時間＝首字延遲 TTFT**




**搬得慢，使用者就等得久**

## 我們怎麼做

先問

**① 回來時怎麼送回最快？**

格式（BF16／INT4）× 送法
（整段搬回／重算／Cake）

GPU 直接量 [實測]

再問

**② GPU 還要做別的事怎麼分？**

MPS（保留給搬回的比例）
vs 單純共用

trace 模擬 ＋ GPU 檢查

最後問

**③ 再加預測，還能省多少？**

「完美預測」的上限、寫入時預知、
免費訊號

trace 模擬 ＋ GPU 重播

**每一步的判定門檻，都在看到數字之前先登記**

## 我們發現

**① 查表就夠**

慢儲存：INT4＋Cake，最慢那層
12.1 秒 → 1.24 秒（快 11.0–40.7%）
CPU 記憶體：看 INT4 怎麼解壓，
差 6.8 倍

**② MPS 是取捨旋鈕**

回答快 30.7–62.9%，別的工作
最多慢 6.5 個百分點；保留越多給
搬回，別的工作越慢

**③ 預測的價值有上限、看紀錄**

agent 紀錄：完美預測也省不到 15%
（128 GiB 時只有 0.30%）
對話紀錄：最多省 50.5%
免費的打字訊號拿到 0.81
寫入時預知：量不到收益

**一句話：先查表選好做法、再分 GPU；要不要蓋預測器，先量「完美預測」的上限再決定**