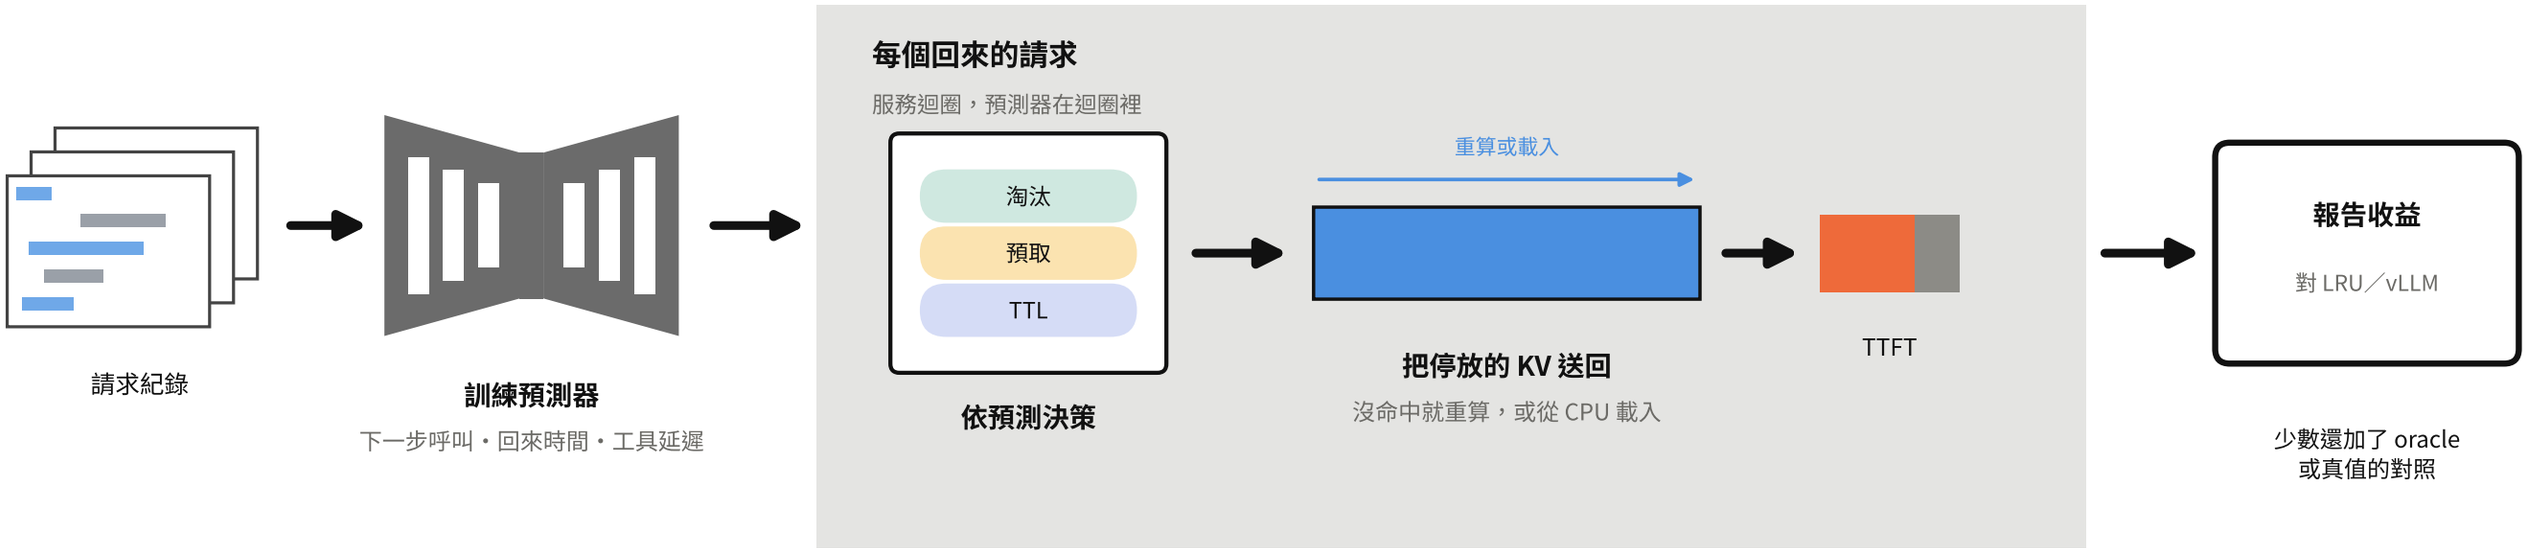
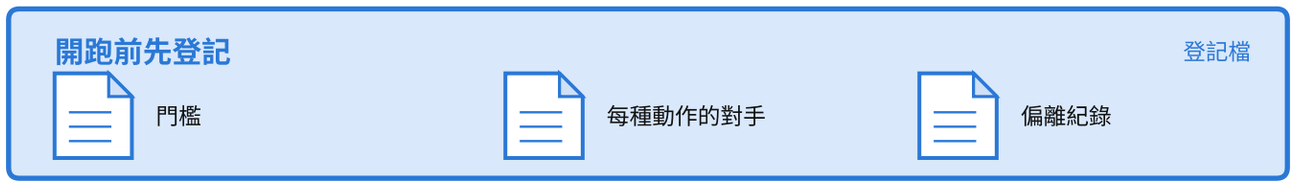
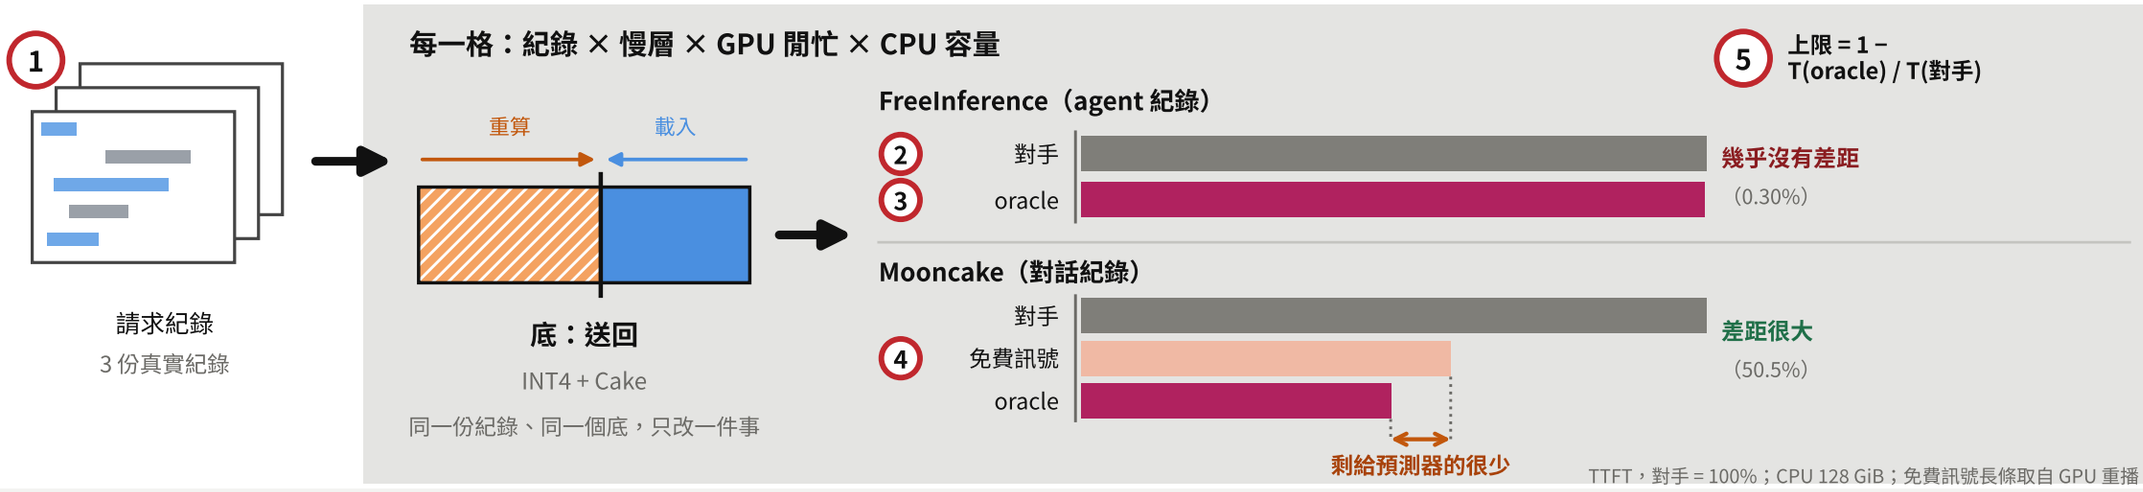
(a) 預測型 KV 管理（例：PBKV、CacheScout、CacheWise、SAGA）



(b) 本文：先量預測在固定的底之上還能再加多少





	預測型研究（對照組已核對全文）	本文
1	**輸入**	一份請求紀錄或 agent 工作流	同一份紀錄＋最好的固定送回（INT4＋Cake）當底
2	**比較**	對 LRU、vLLM 或 SGLang 的前綴快取	對同動作下最好的不預測對手
3	**預知**	學出來或依模式推測的預測器（下一步呼叫、工具延遲）	oracle：一次只知道未來的一件事
4	**免費訊號**	少見（例：工具回報的進度）	使用者一開始打字就預取；拿到完美預取的大部分好處
5	**量測**	對照組的收益；少數加了真值或 oracle 對照	上限 = 1 − T(oracle)/T(對手)；門檻事先登記
6	**輸出**	一個預測器和它報告的收益	每份紀錄：預測還能再加多少