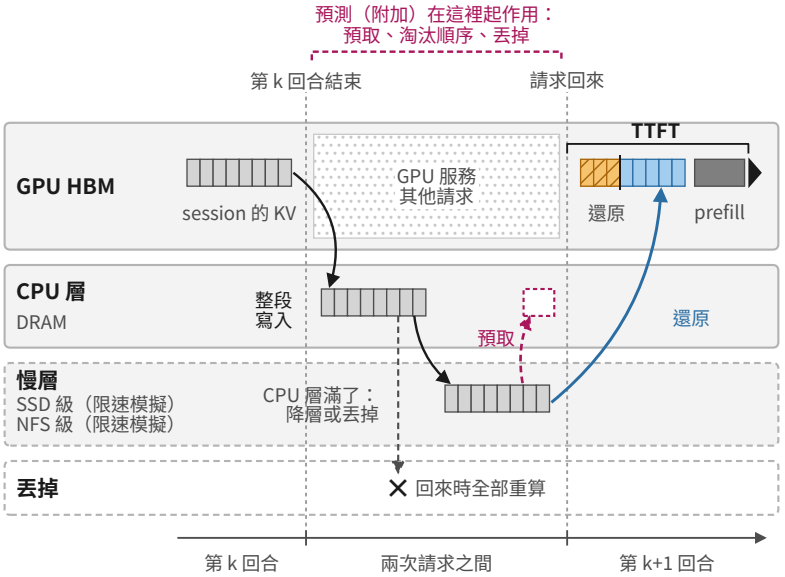
(a) 一個 session 的 KV 在兩次請求之間



(b) 還原這一步可以調的選項

方向	基本組合（地圖內）	附加
重用	全部載入 Cake 全部重算	近似重算
壓縮	BF16　INT4 低秩＋INT4	—
聚焦	—	漸進／ 選擇性還原
擴展	CPU 層　慢層	預測：預取、 淘汰順序、丟掉 借鄰卡多一條路徑
GPU 資源（跨方向）	stream MPS（保留 SM）	借鄰居的算力

基本組合裡的選項　GPU 重算
基本組合之外的附加　載入（I/O）
需要預測的附加（oracle 研究）