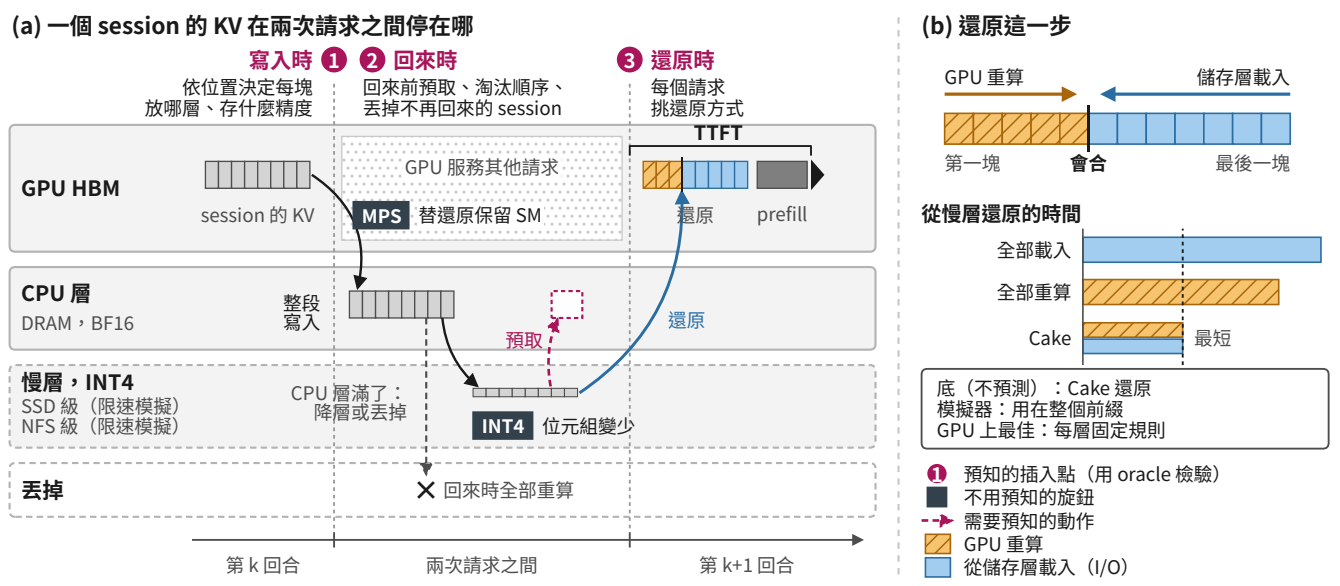

(a) 一個 session 的 KV 在兩次請求之間停在哪
寫入時 1
依位置決定每塊放哪層、存什麼精度
2 回來時
回來前預取、淘汰順序、丟掉不再回來的 session
3 還原時
每個請求挑還原方式
TTFT
GPU HBM
GPU 服務其他請求
session 的 KV
MPS 替還原保留 SM
還原
prefill
CPU 層
DRAM，BF16
整段寫入
預取
還原
慢層，INT4
SSD 級（限速模擬）
NFS 級（限速模擬）
CPU 層滿了：降層或丟掉
INT4 位元組變少
丟掉
✕ 回來時全部重算
第 k 回合
兩次請求之間
第 k+1 回合
(b) 還原這一步
GPU 重算
儲存層載入
第一塊
會合
最後一塊
從慢層還原的時間
全部載入
全部重算
Cake
最短
底（不預測）：Cake 還原
模擬器：用在整個前綴
GPU 上最佳：每層固定規則
1 預知的插入點（用 oracle 檢驗）
不用預知的旋鈕
需要預知的動作
GPU 重算
從儲存層載入（I/O）