真實 trace

Mooncake conversation（chat）

Mooncake toolagent（工具）

FreeInference（agent）

trace 驅動的模擬器

一次一個請求

CPU 層＋GPU 重算：H200 實測

SSD／NFS 級：限速模擬（常數沿用前一個平台）

❷ 回來時的預知

在 GPU 上實測

一張 H200，實際執行

微基準量出
成本常數

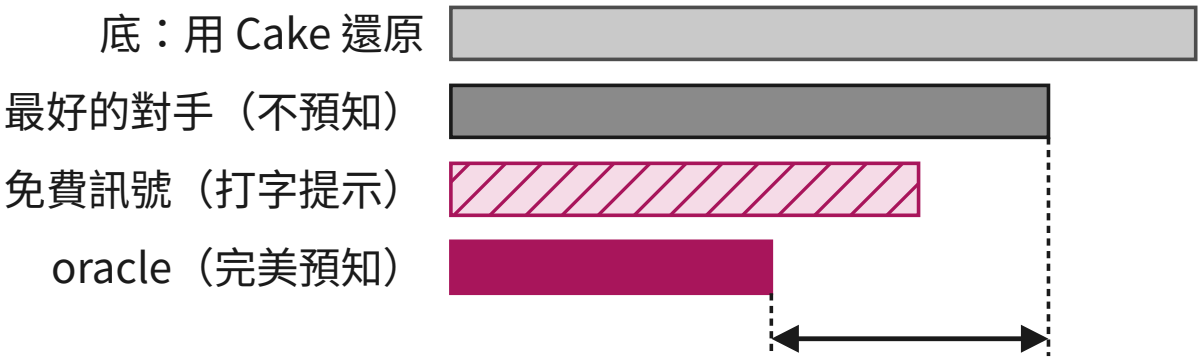
❶ ❸ 寫入時、還原時

INT4　MPS　開與關

縮小重播：
TTFT 實測÷模擬
0.911–0.987，排序相同

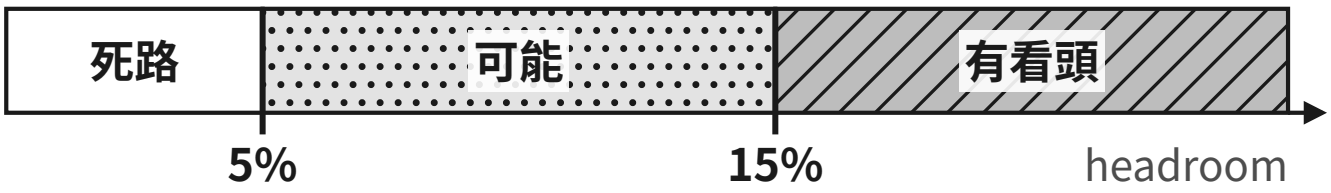
每個決策：同一條 trace 跑四種臂

長條＝回來請求的平均 TTFT（示意）



$$\text{headroom} = 1 - T_{\text{oracle}} / T_{\text{對手}}$$

判定：headroom 落在哪一區



門檻在看到任何結果之前登記