真實 trace

Mooncake conversation（chat）

Mooncake toolagent（工具）

FreeInference（agent）

trace 驅動的模擬器

一次一個請求

CPU 層＋GPU 重算：
H200 實測

SSD／NFS 級：限速模擬
（常數沿用前一個平台）

② 回來時的預知

MPS 取捨曲線

在 GPU 上實測

一張 H200，實際執行

微基準量出
成本常數

① ③ 寫入時、還原時

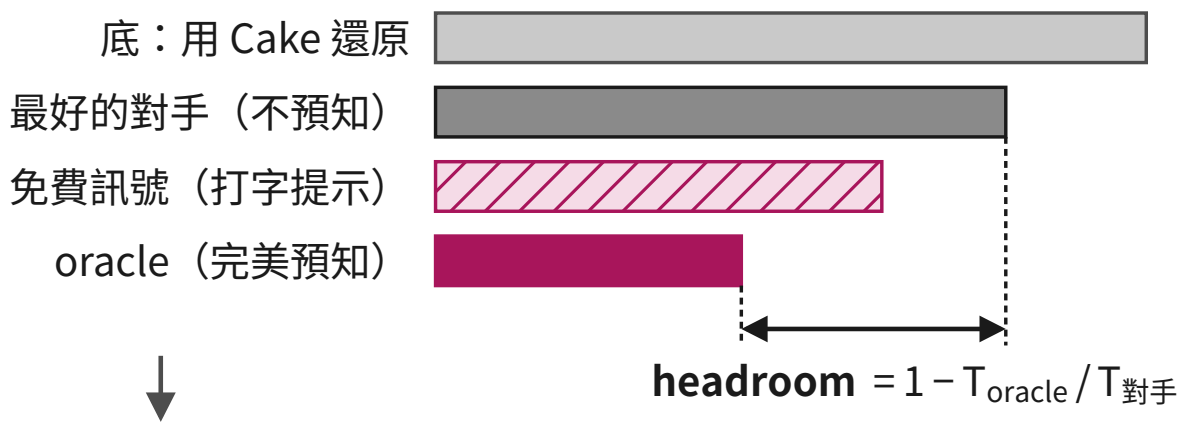
INT4 開與關

MPS 微基準＋GPU 對照

縮小重播：
TTFT 實測÷模擬
0.911–0.987，排序相同

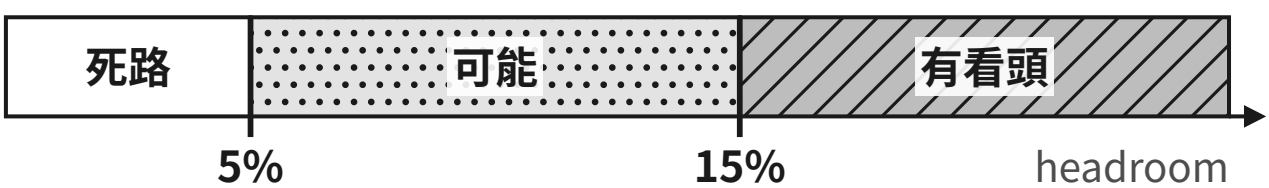
每個決策：同一條 trace 跑四種臂

長條＝回來請求的平均 TTFT（示意）



headroom $= 1 - T_{oracle} / T_{對手}$

判定：headroom 落在哪一區



門檻在看到任何結果之前登記