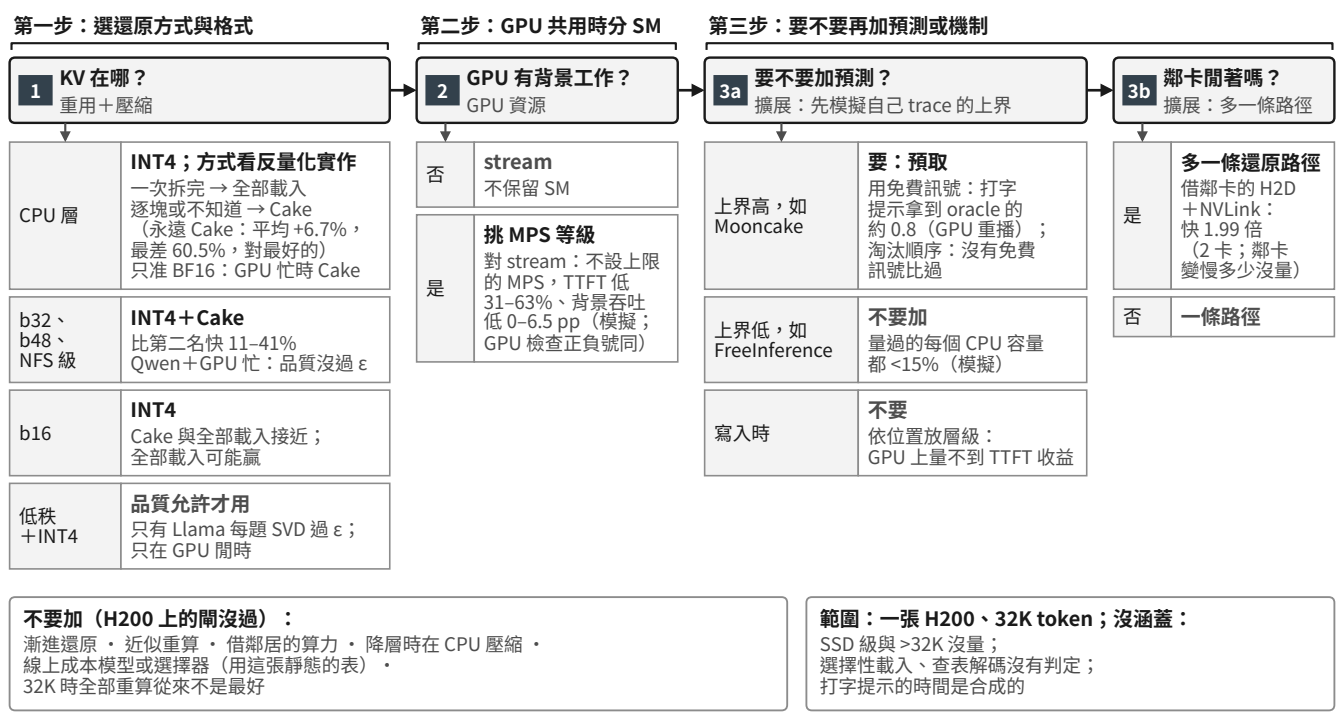

第一步：選還原方式與格式
第二步：GPU 共用時分 SM
第三步：要不要再加預測或機制
1
KV 在哪？
重用＋壓縮
2
GPU 有背景工作？
GPU 資源
3a
要不要加預測？
擴展：先模擬自己 trace 的上界
3b
鄰卡閒著嗎？
擴展：多一條路徑
CPU 層
INT4；方式看反量化實作
一次拆完 → 全部載入
逐塊或不知道 → Cake
（永遠 Cake：平均 +6.7%，
最差 60.5%，對最好的）
只准 BF16：GPU 忙時 Cake
b32、
b48、
NFS 級
INT4＋Cake
比第二名快 11–41%
Qwen＋GPU 忙：品質沒過 ε
b16
INT4
Cake 與全部載入接近；
全部載入可能贏
低秩
＋INT4
品質允許才用
只有 Llama 每題 SVD 過 ε；
只在 GPU 閒時
否
stream
不保留 SM
是
挑 MPS 等級
對 stream：不設上限
的 MPS，TTFT 低
31–63%、背景吞吐
低 0–6.5 pp（模擬；
GPU 檢查正負號同）
上界高，如
Mooncake
要：預取
用免費訊號：打字
提示拿到 oracle 的
約 0.8（GPU 重播）；
淘汰順序：沒有免費
訊號比過
上界低，如
FreeInference
不要加
量過的每個 CPU 容量
都 <15%（模擬）
寫入時
不要
依位置放層級：
GPU 上量不到 TTFT 收益
是
多一條還原路徑
借鄰卡的 H2D
＋NVLink：
快 1.99 倍
（2 卡；鄰卡
變慢多少沒量）
否
一條路徑
不要加（H200 上的閘沒過）：
漸進還原 · 近似重算 · 借鄰居的算力 · 降層時在 CPU 壓縮 ·
線上成本模型或選擇器（用這張靜態的表）·
32K 時全部重算從來不是最好
範圍：一張 H200、32K token；沒涵蓋：
SSD 級與 >32K 沒量；
選擇性載入、查表解碼沒有判定；
打字提示的時間是合成的