

Tiara 實驗報告：平台 B（AMD MI300X）

階層式 KV 放置的成本模型、對照組與品質測
字字字字 2026-09-19 16:10

GPU AMD Instinct MI300X 192 GiB HBM3
vLLM v0.28.0 ROCm 7.2.2 torch 2.12.1+rocm7.2
字字字 7dense 5MoE 113-15B 字 2
字字字字 results/字字字 CSVJSON字字字字字字字字字字

綠色 MEASURED = 實測；橘色 PENDING = 尚未量測，該頁說明會是什麼實驗

實驗覆蓋矩陣 ■ 已完成 □ 尚未量測


	M1 容量	M2 取回	M2 重算	M3 對照	M4 Oracle	無損	撈針	GSM8K	LongBench	RULER	注意力
Llama-3.1-8B	✓	✓	✓	✓	✓	✓	✓	✓	✓	✓	✓
UltraLong-8B-1M	✓	✓	✓	✓	✓	✓	✓	✓	✓	✓	✓
Qwen2.5-7B-1M	✓	✓	✓	✓	✓	✓	✓	✓	✓	✓	✓
Qwen3-30B-A3B (MoE)	✓	✓	✓	✓	✓	✓	✓	✓	✓	✓	✓
Seed-OSS-36B	✓	✓	✓	✓	✓	✓	✓	✓	✓	✓	✓
Qwen2.5-14B-1M	✓	✓	✓	✓	✓	✓	✓	✓	✓	✓	✓
Mistral-Nemo-12B	✓	✓	✓	✓	✓	✓	✓	✓	✓	✓	✓

目前的主要發現

1. 容量：FP8/INT8/INT4 相對 BF16 的容量倍數是 2.00 / 1.94 / 3.77，七個模型一致，且與平台 A（3090）相同 —— 這是跨硬體的不變量。
2. 重算成本不是常數：UltraLong-8B 從位置 0 的 86 ms 長到 1M 的 10,350 ms（120 倍），線性擬合 $R^2 = 0.9993$ 。論文 § 3 的核心假設在平台 B 成立。
3. Oracle go/no-go = GO：合成工作負載在壓力 2–8× 時 headroom 21–43%。
但真實 trace（壓力 6–86×）只有 7–21%，其中 5 格落在「5–15% 要問人」的區間。
判讀：極高壓力下重用本來就少，最佳 baseline 已接近極限 —— 應寫成適用範圍限制。
4. KV 量化的品質代價是「模型 × 任務」的性質，不是量化本身的性質：
Llama-3.1-8B / Qwen3-MoE / Seed-OSS / UltraLong 在 64K–129K 下五種精度全部 100%；
但 Qwen2.5-7B-1M 在 3K 就崩潰（FP8 15%、INT4 0%），且是語言能力崩潰（吐垃圾），不是檢索失敗。平台 A 在同家族模型上量到同一模式 —— 跨平台重現。
5. 卸載是位元組無損的，但端到端不是位元相同：
CPU 階 vs 磁碟階 0/60 不同（搬移無損）、同設定重跑 0/60（執行決定性），
但兩者 vs 不卸載有 16–25/60 不同 —— 差異來自「取回+部分重算」與「整段 prefill」
的浮點路徑不同。這是必須寫進論文的實作事實。
6. 注意力重要度與跨請求重用正交：AUC 0.488（≈隨機）vs 存取歷史 0.721，
Spearman -0.016。原因：注意力幾乎完全由位置決定（同位置跨請求變異係數 0.0085，
位置間 0.3306，差 38.8 倍）。→ 論文表 15 (C) 的 attn_mass 那格可以填「無貢獻」。

M1：KV 容量 —— 低精度用容量換品質的「本錢」

每個模型能放多少 KV



量化換到的容量（實測 vs 理論）




表 1 M1：GPU KV 容量（token）與量化倍數

模型	BF16	FP8	INT8	INT4	FP8/BF16	INT8/BF16	INT4/BF16	模型可定址長度	上限來自
Llama-3.1-8B	1,271,024	2,535,008	2,465,024	4,771,792	1.994	1.939	3.754	131,072	模型上限
UltraLong-8B-1M	1,265,520	2,531,040	2,454,336	4,764,320	2.000	1.939	3.765	1,073,152	模型上限
Qwen2.5-7B-1M	2,889,696	5,817,152	5,604,272	10,878,880	2.013	1.939	3.765	262,144	模型上限
Qwen3-30B-A3B (MoE)	947,536	1,895,088	1,837,664	3,567,008	2.000	1.939	3.765	262,144	模型上限
Seed-OSS-36B	413,632	827,264	802,192	1,557,200	2.000	1.939	3.765	524,288	記憶體
Qwen2.5-14B-1M	769,664	1,539,328	1,492,688	2,897,568	2.000	1.939	3.765	262,144	模型上限
Mistral-Nemo-12B	964,144	1,928,304	1,869,856	3,629,744	2.000	1.939	3.765	131,072	模型上限

結論：七個模型的量化倍數一致收斂到 2.00／1.94／3.77，與平台 A（RTX 3090）相同 —— 這是跨硬體、跨模型的不變量，
可以當成論文中「精度階換容量」的係數直接引用。INT8 之所以是 1.94 而非 2.00，是每 token 每 head 的縮放中繼資料佔掉的。
七個模型只有 Seed-OSS-36B 的 BF16 上限來自記憶體（413,632 < 模型可定址的 524,288），其餘都先撞到模型自身的長度上限。

M2：把 KV 變回可用要多少錢（減掉「本來就在 GPU」的基準）




表 2 M2：各階的取回成本（warm TTFT 減「本來就在 GPU」的基準）

模型	ctx	階	warm TTFT ms	減基準 ms	μs/token	等效 GB/s	前綴 KV GiB
Llama-3.1-8B	16,384	GPU FP8	84.5	2.7	0.17	792.137	2.00
Llama-3.1-8B	16,384	GPU INT4	107.8	26.1	1.59	82.311	2.00
Llama-3.1-8B	16,384	CPU	581.9	500.1	30.52	4.294	2.00
Llama-3.1-8B	16,384	SSD	1,145.3	1,063.6	64.92	2.019	2.00
Llama-3.1-8B	16,384	丟掉重算	847.6	765.8	46.74	2.804	2.00
Qwen2.5-7B-1M	96,000	CPU	2,899.4	2,253.9	23.48	2.442	5.13
Qwen2.5-7B-1M	96,000	SSD	4,908.6	4,263.1	44.41	1.291	5.13
Qwen2.5-7B-1M	96,000	丟掉重算	10,706.6	10,061.1	104.80	0.547	5.13
Qwen3-30B-A3B (MoE)	96,000	CPU	696.0	-49.1	-0.51	—	8.79
Qwen3-30B-A3B (MoE)	96,000	SSD	3,715.4	2,970.4	30.94	3.177	8.79
Qwen3-30B-A3B (MoE)	96,000	丟掉重算	17,891.0	17,146.0	178.60	0.55	8.79
Seed-OSS-36B	96,000	CPU	6,283.4	5,411.2	56.37	4.651	23.44
Seed-OSS-36B	96,000	SSD	12,426.7	11,554.4	120.36	2.178	23.44
Seed-OSS-36B	96,000	丟掉重算	63,923.2	63,050.9	656.78	0.399	23.44

結論：同一張卡上，CPU 階的等效頻寬從 2.3 到 37.8 GB/s（16 倍差距，見發現 11 的 Qwen3-MoE）——κ 不只跨硬體變動，**跨模型也變動**。
GPU 內的精度階（FP8／INT4）反量化成本極小（0.17／1.59 μs/token），相對於 CPU 的 23–56、SSD 的 44–120 μs/token 幾乎免費。
△Llama-3.1-8B 量於 ctx=16,384，其餘為 96,000；重算成本與位置成正比，故「丟掉重算」那一欄不可跨 ctx 直接比較。


表 3 M2：重算成本的線性擬合 $C_{\text{recompute}}(P) = C_0 + a \cdot P$

模型	C0 (ms)	a (μs/千 token)	R ²	位置數	chunk
Llama-3.1-8B	101.5	9.25	0.9998	8	2,048
Mistral-Nemo-12B	128.3	8.58	0.9997	9	2,048
Qwen2.5-14B-1M	128.8	16.83	0.9999	11	2,048
Qwen3-30B-A3B (MoE)	89.5	11.83	0.9999	11	2,048
Qwen2.5-7B-1M	96.0	9.22	0.9469	11	2,048
Seed-OSS-36B	408.3	30.76	0.9993	13	2,048
UltraLong-8B-1M	44.8	9.75	0.9993	12	2,048

結論：七個模型的 R² 都 ≥ 0.947（五個 ≥ 0.999），證實論文 § 3 的「C_recompute 不是常數、隨位置線性成長」。

兩個 8B 模型的斜率幾乎相同（9.25／9.75 μs/千 token），Seed-OSS-36B 是它們的 3.3 倍——斜率隨模型規模放大，所以「丟掉重算」這個動作在大模型上昂貴得多，這正是階層放置對大模型更有價值的原因。

M2：重算成本隨位置線性成長 —— 論文「C_recompute 不是常數」的證據



M3：工作集塞不下 GPU 之後，四個對照組的取回延遲（越低越好）




表 4 M3：四個對照組的 cold／warm TTFT（ms，中位數）

模型	ctx	不卸載 cold	warm	LRU cold	warm	ARC cold	warm	CPU+磁碟 cold	warm
Llama-3.1-8B	4,096	172	39	197	43	196	45	208	43
Llama-3.1-8B	8,192	367	65	465	68	462	65	483	66
Llama-3.1-8B	16,384	860	859	1,309	589	1,306	583	1,329	586
Llama-3.1-8B	32,768	2,276	2,272	4,649	1,139	4,647	4,260	4,675	2,234
UltraLong-8B-1M	8,192	355	51	439	54	445	57	460	56
UltraLong-8B-1M	16,384	857	86	1,293	83	1,301	93	1,331	92
UltraLong-8B-1M	32,768	2,272	2,273	4,193	1,115	4,207	1,126	4,239	1,125
UltraLong-8B-1M	65,536	6,893	6,893	14,591	2,198	14,604	11,167	14,653	4,421
Qwen2.5-7B-1M	8,192	321	70	415	67	411	62	438	59
Qwen2.5-7B-1M	16,384	738	122	1,158	101	1,155	98	1,192	100
Qwen2.5-7B-1M	32,768	1,891	1,897	3,812	1,009	3,807	988	3,857	1,001
Qwen2.5-7B-1M	65,536	5,563	5,549	12,747	1,973	12,734	11,467	12,821	3,333
Qwen3-30B-A3B (MoE)	8,192	346	91	529	61	532	60	545	56
Qwen3-30B-A3B (MoE)	16,384	903	156	1,694	90	1,703	98	1,722	94
Qwen3-30B-A3B (MoE)	32,768	2,670	2,676	6,005	248	6,020	261	6,041	250
Qwen3-30B-A3B (MoE)	65,536	8,900	8,899	22,433	469	22,473	16,272	22,525	2,539
Seed-OSS-36B	8,192	1,495	136	2,578	94	2,575	92	2,599	94
Seed-OSS-36B	16,384	3,774	196	8,179	122	8,169	132	8,220	128
Seed-OSS-36B	32,768	10,352	10,344	28,988	2,142	28,920	2,132	29,020	2,161
Seed-OSS-36B	65,536	32,214	32,223	105,053	4,250	104,861	75,873	104,977	8,533
Qwen2.5-14B-1M	8,192	618	90	821	81	822	83	841	87
Qwen2.5-14B-1M	16,384	1,502	153	2,443	102	2,455	102	2,487	104
Qwen2.5-14B-1M	32,768	4,039	4,034	8,625	1,601	8,632	1,642	8,365	1,632
Qwen2.5-14B-1M	65,536	12,368	12,376	28,371	3,207	28,353	21,134	28,405	6,022


表 4 M3：四個對照組的 cold／warm TTFT（ms，中位數）（續 2）

模型	ctx	不卸載 cold	warm	LRU cold	warm	ARC cold	warm	CPU+磁碟 cold	warm
Mistral-Nemo-12B	8,192	480	42	602	53	599	51	612	49
Mistral-Nemo-12B	16,384	1,145	64	1,704	95	1,702	91	1,731	92
Mistral-Nemo-12B	32,768	2,986	2,965	5,377	1,301	5,375	1,322	5,407	1,337
Mistral-Nemo-12B	65,536	8,870	8,882	19,209	2,589	19,222	14,496	18,563	5,080


結論：工作集塞不下 GPU 之後，「不卸載」的 warm $\approx$ cold（省 0%），卸載可省 73–98%。
LRU 與 ARC 在最大 ctx 上差距極大（Seed-OSS 65K：4,250 ms vs 75,874 ms）—— 這正是 EXPERIMENT_PLAN 要求的檢查：
兩者數字若相同就代表卸載根本沒發生。這裡確認有發生，且 Oracle 之後要贏的是這裡面最強的那個。

M4 : Oracle go/no-go —— 整個研究的停損點

合成工作負載 (Zipf $\alpha=0.9$)



真實 trace (Mooncake, 前 4,000 個請求)



MEASURED

表 5 M4：Oracle 相對最佳 baseline 的改善（headroom）

模型	壓力 1x	壓力 2x	壓力 4x	壓力 8x	對話 trace	工具代理 trace	最常見的最佳 baseline
Llama-3.1-8B	0.0%	35.2%	37.6%	33.5%	20.9%	20.7%	cpu_arc
UltraLong-8B-1M	0.0%	39.1%	38.7%	33.5%	20.8%	20.6%	cpu_arc
Qwen2.5-7B-1M	0.0%	33.2%	39.4%	34.0%	15.3%	11.5%	cpu_arc
Qwen3-30B-A3B (MoE)	0.0%	5.9%	39.8%	43.0%	9.8%	9.5%	cpu_arc
Seed-OSS-36B	0.0%	21.9%	39.7%	39.8%	6.9%	7.2%	tier_fs
Qwen2.5-14B-1M	0.0%	32.7%	39.5%	35.1%	14.6%	14.9%	cpu_arc
Mistral-Nemo-12B	0.0%	35.0%	39.7%	34.4%	19.9%	20.4%	cpu_arc

結論：判準是 >15% 繼續、5–15% 問人、<5% 停止。合成工作負載在壓力 2–8× 時 headroom 21–43% → **GO**。


壓力 1× 一律 0.0%，因為工作集塞得進 GPU，最佳 baseline 就是不卸載，沒有放置決策可做 —— 這是正確的退化行為。

真實 trace（實際壓力 6–86×）只有 7–21%：極高壓力下重用本來就少，最強 baseline 已接近極限。


這不是否證，而是適用範圍：階層放置的價值集中在「塞不下但仍有重用」的中等壓力區。

M5：KV 量化的品質代價 —— 只看 GSM8K 會得出「量化免費」的錯誤結論

大海撈針（長距離檢索）




GSM8K many-shot（推理）




M5：標準評測跑分 —— 五種 KV 精度的差距在 ± 1 分內

LongBench（7 個英文任務）



RULER（合成，16K）



MEASURED

表 6 M5：四套評測 × 五種 KV 精度的分數


模型	評測	BF16	FP8	FP8動態	INT8	INT4
Llama-3.1-8B	撈針 %	100.0	100.0	100.0	100.0	100.0
Llama-3.1-8B	GSM8K %	80.8	75.8	82.5	79.2	75.8
Llama-3.1-8B	LongBench	57.1	56.4	56.7	57.2	56.7
Llama-3.1-8B	RULER	91.3	91.5	90.6	92.1	92.6
UltraLong-8B-1M	撈針 %	100.0	100.0	100.0	100.0	100.0
UltraLong-8B-1M	GSM8K %	68.3	66.7	74.2	67.5	67.5
UltraLong-8B-1M	LongBench	53.6	53.8	53.6	52.9	52.4
UltraLong-8B-1M	RULER	91.1	92.0	92.2	91.5	90.0
Qwen2.5-7B-1M	撈針 %	100.0	10.0	0.0	90.0	0.0
Qwen2.5-7B-1M	GSM8K %	90.8	0.0	0.0	88.3	0.0
Qwen2.5-7B-1M	LongBench	59.2	30.2	2.2	57.4	0.4
Qwen2.5-7B-1M	RULER	93.4	11.2	0.7	69.0	0.0
Qwen3-30B-A3B (MoE)	撈針 %	100.0	100.0	100.0	100.0	100.0
Qwen3-30B-A3B (MoE)	GSM8K %	95.8	97.5	96.7	95.0	95.8
Qwen3-30B-A3B (MoE)	LongBench	59.6	59.8	58.7	59.7	58.6
Qwen3-30B-A3B (MoE)	RULER	95.1	95.3	95.0	95.2	94.6
Seed-OSS-36B	撈針 %	100.0	100.0	100.0	100.0	100.0
Seed-OSS-36B	GSM8K %	92.5	94.2	93.3	94.2	90.0
Seed-OSS-36B	LongBench	20.1	20.1	20.6	20.1	19.9
Seed-OSS-36B	RULER	46.2	47.1	45.0	46.6	46.6
Qwen2.5-14B-1M	撈針 %	100.0	100.0	100.0	100.0	100.0
Qwen2.5-14B-1M	GSM8K %	90.0	89.2	91.7	90.8	91.7
Qwen2.5-14B-1M	LongBench	61.4	61.5	61.6	61.2	61.4
Qwen2.5-14B-1M	RULER	92.5	93.5	91.9	91.8	92.4

表 6 M5：四套評測 × 五種 KV 精度的分數（續 2）

模型	評測	BF16	FP8	FP8動態	INT8	INT4
Mistral-Nemo-12B	撈針 %	100.0	100.0	100.0	100.0	95.0
Mistral-Nemo-12B	GSM8K %	74.2	71.7	74.2	74.2	66.7
Mistral-Nemo-12B	LongBench	54.4	53.1	54.0	53.2	54.2
Mistral-Nemo-12B	RULER	94.4	94.6	93.6	94.6	94.0

結論：ε（品質代價）是「模型 × 任務」的性質，不是精度本身的性質。
Llama-3.1-8B／UltraLong／Qwen3-MoE／Seed-OSS 在 64K-129K 下，連 INT4 都看不到可辨識的損失（四套評測皆然）。
唯一例外 Qwen2.5-7B-1M：撈針從 100% 掉到 0%，且在 3K 就發生（非長度效應），輸出是重複字元／空字串等退化生成 —— 是崩潰不是品質下降。
實務意涵：Oracle 使用低精度階前，必須對該模型先跑一次檢索型檢查；通過的模型可以放心用 INT4 換 3.77 倍容量。

M5：卸載的無損性 —— 兩條卸載路徑彼此完全一致，但與「不卸載」不同



決定性對照：同一個 full_gpu 設定跑兩次 → 0/60 位元不同，所以上圖的差異不是雜訊。

results/m5_cpu_vs_disk_stage = 0% loss for 10 models. 位元組搬移本身無損；差異來自「取回+部分重算」與「整段 prefill」的浮點路徑不同。

MEASURED

表 7 M5：卸載的無損性（輸出 sha1 不同的題數／可比題數）

模型	不卸載 vs CPU階	不卸載 vs 磁碟階	CPU階 vs 磁碟階	答案不同（CPU階）	正確數 不卸載	CPU階	磁碟階
Llama-3.1-8B	18/60	18/60	0/60	4	47/60	46/60	46/60
Llama-3.1-8B	0/0	0/0	0/0	0	—	—	14/20
Mistral-Nemo-12B	0/0	13/60	0/0	0	44/60	—	43/60
Mistral-Nemo-12B	13/60	13/60	0/60	4	44/60	43/60	43/60
Qwen2.5-14B-1M	0/0	14/60	0/0	0	56/60	—	57/60
Qwen2.5-14B-1M	14/60	14/60	0/60	1	56/60	57/60	57/60
Qwen3-30B-A3B (MoE)	25/60	25/60	0/60	1	58/60	58/60	58/60
Qwen2.5-7B-1M	20/60	20/60	0/60	1	55/60	54/60	54/60
Seed-OSS-36B	16/60	16/60	0/60	1	56/60	56/60	56/60
UltraLong-8B-1M	18/60	18/60	0/60	3	40/60	39/60	39/60

結論：CPU 階 vs 磁碟階 = 0/60（完全一致）→ **位元組搬移本身無損**；同設定重跑也是 0/60 → 執行是決定性的。
但兩者 vs 不卸載有 13-25/60 不同 —— 差異來自「取回 + 部分重算」與「整段 prefill」走不同的浮點路徑（分塊邊界不同）。
正確率影響極小（最多差 1 題）。這與平台 A 的 60/60 完全相同不一致，必須在論文中標明為平台相依的實作事實。

目（兩訊號正交） Spearman Llama-3.1-8B: -0.016, Mistral-Nemo-12B: -0.019, Qwen2.5-14B-1M: -0.047, Qwen3-30B-A3B (MoE): -0.039, Qwen2.5-7B-1M: +0.051, Seed-OS






表 8 M5-C：注意力重要度 vs 存取歷史（預測「block 會被重用」）

模型	樣本數	正例率	注意力 AUC	存取歷史 AUC	Spearman	文件×token	請求數	horizon
Llama-3.1-8B	55,296	0.768	0.488	0.721	-0.016	24×4096	240	32
Mistral-Nemo-12B	55,296	0.768	0.489	0.721	-0.019	24×4096	240	32
Qwen2.5-14B-1M	55,296	0.768	0.480	0.721	-0.047	24×4096	240	32
Qwen3-30B-A3B (MoE)	55,296	0.768	0.484	0.721	-0.039	24×4096	240	32
Qwen2.5-7B-1M	55,296	0.768	0.500	0.721	+0.051	24×4096	240	32
Seed-OSS-36B	55,296	0.768	0.499	0.721	-0.003	24×4096	240	32
UltraLong-8B-1M	55,296	0.768	0.487	0.721	-0.025	24×4096	240	32

結論：注意力重要度的 AUC $\approx$ 0.5（等於丟銅板），存取歷史 0.72，兩者相關 $\approx$ 0 $\rightarrow$ **兩個訊號正交**。
原因已量化：注意力幾乎完全由位置決定（同位置跨請求的變異係數 0.0085，位置之間 0.3306，差 38.8 倍；同文件兩次請求的前 50 名 block 重疊率 100%），而跨請求重用取決於「哪份文件又被查」。
對論文：表 15 (C) 的 attn_mass 特徵族可以填「已量測、對重用預測無貢獻」，並支持現行以存取歷史為特徵的設計。
△ 這不否定注意力重要度在「單次請求內選擇保留哪些 token」上的效用（H2O／SnapKV 已充分驗證）。

M5：學習式放置預測器

預測器的判別力



前 12 名特徵




表 9 M5：學習式重用預測器（LightGBM）

trace	損失	門檻規則	AUC	ECE	AP	Spearman(正樣本)	測試樣本	成本加權錯誤 ms	推論 μs
conversation	sym_l2	0.5	0.9172	0.0033	0.8140	0.9906	673,526	7,981	248
conversation	sym_l2	p_star	0.9172	0.0033	0.8140	0.9906	673,526	8,001	248
conversation	cost_l2	0.5	0.9216	0.0041	0.8424	0.9908	673,526	7,800	271
conversation	cost_l2	p_star	0.9216	0.0041	0.8424	0.9908	673,526	8,063	271
conversation	sym_l2	0.5	0.9172	0.0033	0.8140	0.9906	673,526	7,981	237
conversation	sym_l2	p_star	0.9172	0.0033	0.8140	0.9906	673,526	8,001	237
conversation	cost_l2	0.5	0.9216	0.0041	0.8424	0.9908	673,526	7,800	268
conversation	cost_l2	p_star	0.9216	0.0041	0.8424	0.9908	673,526	8,063	268
toolagent	sym_l2	0.5	0.9920	0.0023	0.9934	0.2744	946,256	4,624	126
toolagent	sym_l2	p_star	0.9920	0.0023	0.9934	0.2744	946,256	5,108	126
toolagent	cost_l2	0.5	0.9921	0.0025	0.9936	0.2583	946,256	4,638	138
toolagent	cost_l2	p_star	0.9921	0.0025	0.9936	0.2583	946,256	4,962	138
lc128kz	sym_l2	0.5	0.2768	0.2951	0.5156	0.0568	69,225	12,747	29
lc128kz	sym_l2	p_star	0.2768	0.2951	0.5156	0.0568	69,225	12,747	29
lc128kz	cost_l2	0.5	0.2622	0.3882	0.5714	-0.2380	69,225	12,147	32
lc128kz	cost_l2	p_star	0.2622	0.3882	0.5714	-0.2380	69,225	12,147	32
lc128kz	sym_l2	0.5	0.4921	0.2447	0.2700	0.0514	370,091	459,875	34
lc128kz	sym_l2	p_star	0.4921	0.2447	0.2700	0.0514	370,091	145,324	34
lc128kz	cost_l2	0.5	0.4711	0.2350	0.2607	-0.0334	370,091	471,278	33
lc128kz	cost_l2	p_star	0.4711	0.2350	0.2607	-0.0334	370,091	165,894	33
toolagent	sym_l2	0.5	0.9995	0.0004	0.9994	0.2455	950,227	1,461	129
toolagent	sym_l2	p_star	0.9995	0.0004	0.9994	0.2455	950,227	1,332	129
toolagent	cost_l2	0.5	0.9994	0.0004	0.9993	0.2549	950,227	1,461	140
toolagent	cost_l2	p_star	0.9994	0.0004	0.9993	0.2549	950,227	1,461	140

結論：只用存取歷史特徵（間隔、指數衰減計數、靜態欄位）即可達到 AUC 0.92、校準誤差 ECE 0.003。
成本加權損失相對對稱損失的差別很小，說明在這個工作負載下「錯誤的方向」不像「錯誤的量」那麼關鍵。
推論延遲數百微秒／64 個候選，相對 CPU 階 0.4–1.0 ms/block 的搬運成本是可接受的決策開銷。

尚未完成的實驗（以及它們會回答什麼）

以下是**還沒跑完**的項目。每一項都已寫好腳本並排入佇列，只差機器時間。

【GPU 佇列】

1. LongBench / RULER 跑分 —— 還缺 4 個模型（UltraLong、Qwen2.5-7B、Qwen3-MoE、Mistral-Nemo）

會回答：KV 精度在標準長文評測上的 ϵ ，是否與撈針／GSM8K 一致

2. 注意力對齊實驗 —— UltraLong 進行中、Qwen2.5-14B 排隊

會回答：「注意力重要度無法預測跨請求重用」是否跨模型成立

3. 無損驗證補跑 —— Qwen2.5-14B 與 Mistral-Nemo 的 cpu_lru 那一格

（前次因 /dev/shm 被塞滿而失敗，清理邏輯已修）

【CPU 佇列（模擬與訓練，不佔 GPU）】

4. M4 Oracle 全模型重跑 —— 7 個模型 $\times$ (驗證 + 壓力掃描 + 2 個真實 trace)

為什麼重跑：原本固定寫 oracle.csv，7 個模型互相覆蓋，只剩最後一次的 20 列

5. 平台 A 做過、B 還缺的掃描：預算掃描、SSD 容量掃描、依長度分解、

硬體掃描、語意消融、最終判定書

6. M5 學習式預測器（LightGBM）訓練 + 政策模擬 + 摘要

會回答：用存取歷史預測重用的 AUC／校準誤差，以及換成成本加權損失後的差別

【已知限制，不打算補】

- LMCache 對照組：依賴 CUDA 專屬套件（cupy-cuda13x、cuda-python），ROCm 上裝不起來。

會記為 NOT_MEASURED 並附完整原因，不用別的東西頂替。

- 平台 A 的 tier_fs 設定與 B 不同（A 的 CPU 階 $\geq$ 工作集，磁碟階可能沒被用到），

兩平台的 tier_fs 不可直接比較。